

**FUNDAÇÃO DE ASSISTÊNCIA E EDUCAÇÃO
CENTRO UNIVERSITÁRIO ESPÍRITO-SANTENSE
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO**

**ANA LUIZA MENELLI TAYLOR
DANTON BARBOSA TORRES AMORIM
FELIPE VALÉRIO ROCHA
KAROLINY VICENTE FRANCO**

RELATÓRIO - PROJETO INTEGRADOR IV

**VITÓRIA
2026**

**ANA LUIZA MENELLI TAYLOR
DANTON BARBOSA TORRES AMORIM
FELIPE VALÉRIO ROCHA
KAROLINY VICENTE FRANCO**

RELATÓRIO - PROJETO INTEGRADOR IV

Trabalho acadêmico do Curso de Graduação em Ciência da Computação, apresentado ao Centro Universitário Espírito-Santense, como parte das exigências da disciplina Projeto Integrador Computação IV, sob orientação do prof.º Howard Cruz Roatti.

**VITÓRIA
2026**

SUMÁRIO

1 ESCOPO DO PROJETO.....	3
1.1 Tema do Projeto.....	3
1.2 Problema de Pesquisa.....	3
1.3 Objetivo Geral.....	3
1.4 Objetivos Específicos.....	3
2 JUSTIFICATIVA DO TEMA.....	5
3 DESCRIÇÃO DA SOCIEDADE IMPACTADA.....	7
4 METODOLOGIA.....	9
4.1 Fontes de Dados e Coleta.....	9
4.2 Ferramentas e Infraestrutura Tecnológica.....	9
4.3 Técnicas de Inteligência Artificial e Processamento.....	10
4.4 Estratégia de Verificação e Validação de Software.....	11
4.5 Métricas de Avaliação.....	12
4.6 Aspectos Éticos e de Privacidade.....	13
5 PLANO DE TRABALHO.....	14
REFERÊNCIAS.....	15

1 ESCOPO DO PROJETO

Este capítulo define as diretrizes centrais do projeto, delimitando seu tema, o problema a ser investigado e os objetivos que guiarão o desenvolvimento e a implementação do sistema de rastreamento ocular.

1.1 Tema do Projeto

Classificação de padrões de leitura infantis (fixações, sacadas e regressões) por meio de rastreamento ocular via webcam, utilizando visão computacional e aprendizado de máquina para fornecer suporte e adaptações pedagógicas aos professores.

1.2 Problema de Pesquisa

O projeto busca responder à seguinte questão central: Modelos preditivos treinados com dados de rastreamento ocular de alta precisão mantêm acurácia preditiva pedagogicamente útil quando submetidos à degradação de sinal (redução de taxa de amostragem e ruído espacial) típica de webcams comuns? A partir dessa premissa, investiga-se como viabilizar a identificação de padrões de leitura atípicos no ambiente escolar, de forma acessível, sem a necessidade de hardwares dedicados de alto custo, garantindo total privacidade e adequação à LGPD.

1.3 Objetivo Geral

Desenvolver o EyeLearn, um sistema de rastreamento ocular baseado em webcam capaz de extrair características do percurso do olhar durante atividades de leitura e, por meio de modelos de aprendizado de máquina treinados em bases de dados públicas, classificar o padrão observado para auxiliar professores em adaptações pedagógicas, sem finalidade de diagnóstico clínico.

1.4 Objetivos Específicos

Para alcançar o objetivo geral, o projeto estabelece as seguintes metas específicas:

- **Capturar e estimar o olhar:** Utilizar as bibliotecas OpenCV e MediaPipe Face Landmarker para extrair as coordenadas do olhar em tempo real via webcam.

- **Extrair métricas de leitura:** Processar as séries temporais de coordenadas utilizando algoritmos baseados em velocidade (I-VT) e dispersão (I-DT) para mapear fixações, sacadas e regressões.
- **Simular e analisar a degradação de sinal:** Realizar experimentos de degradação artificial (adição de ruído gaussiano e redução de amostragem) em bases de dados de alta precisão, estabelecendo os limites de viabilidade de hardwares de baixo custo.
- **Treinar e comparar modelos preditivos:** Desenvolver, testar e comparar diferentes arquiteturas de aprendizado de máquina (como SVM, Random Forest, XGBoost e Redes Neurais Convolucionais 1D) utilizando bases públicas anonimizadas (como ETDD70 e Rojas-Líbano et al.) para a classificação dos padrões de leitura.
- **Garantir a confiabilidade do software:** Aplicar técnicas rigorosas de engenharia de software, incluindo testes unitários, testes baseados em propriedades, testes metamórficos e de mutação, assegurando também a ausência de vazamento de dados (*data leakage*).
- **Assegurar a privacidade (LGPD):** Implementar uma arquitetura de processamento local estrita, em que os quadros de vídeo são descartados da memória imediatamente após a extração das coordenadas, sem gravação ou tráfego de imagens faciais em rede.
- **Desenvolver painel de visualização:** Construir uma interface gráfica (PyQt6 e Matplotlib) que traduza os padrões extraídos em indicadores claros para o professor, sugerindo adaptações pedagógicas sem finalidade diagnóstica.

2 JUSTIFICATIVA DO TEMA

O acompanhamento do desenvolvimento da leitura é um dos desafios mais críticos nos anos iniciais da educação. Dificuldades de aprendizagem e condições atípicas do neurodesenvolvimento, como dislexia e Transtorno do Déficit de Atenção com Hiperatividade (TDAH), impactam diretamente o percurso escolar da criança. O rastreamento ocular (*eye-tracking*) é cientificamente reconhecido como uma técnica eficaz para mapear o processo cognitivo da leitura, evidenciado pelo estudo de fixações, regressões e sacadas. No entanto, a exigência de hardwares dedicados e de altíssimo custo historicamente restringe o uso dessa tecnologia a laboratórios de pesquisa, mantendo-a distante do chão de fábrica da educação: a sala de aula.

Nesse contexto, a importância do EyeLearn justifica-se pelo seu elevado potencial de democratização e impacto social. Ao viabilizar o rastreamento ocular por meio de webcams comuns, o projeto transforma um recurso antes inacessível em uma ferramenta viável para as escolas. É fundamental ressaltar que o sistema não possui caráter de avaliação clínica ou diagnóstico médico — responsabilidade exclusiva de profissionais habilitados —, mas atua como um instrumento de apoio pedagógico. Ele traduz o comportamento ocular da criança em dados tangíveis para o professor, permitindo que este crie adaptações metodológicas mais assertivas, personalizadas e precoces para os alunos que apresentam padrões de leitura divergentes da média da turma.

No cenário tecnológico e jurídico atual, o tratamento de dados biométricos e faciais levanta discussões críticas, especialmente quando envolve o público infantil. A abordagem metodológica deste projeto justifica-se fortemente por seu compromisso ético e legal. Em estrita conformidade com a Lei Geral de Proteção de Dados (LGPD), o EyeLearn inova ao realizar todo o processamento computacional na memória local da máquina, descartando os quadros de vídeo instantaneamente após a extração das coordenadas. Ao garantir que nenhuma imagem facial seja armazenada ou enviada pela rede, o projeto prova que é possível aliar inteligência artificial aplicada à educação com segurança da informação e proteção absoluta da privacidade.

Por fim, a viabilidade técnica da proposta apoia-se em um ecossistema robusto de tecnologias de código aberto (como Python, OpenCV e XGBoost) e nas práticas de Ciência Aberta. O treinamento dos modelos dispensou a coleta invasiva de dados infantis, valendo-se do reuso de bases de dados públicas, rigorosamente consolidadas e anonimizadas por pesquisadores da área (como a base ETDD70 e a de Rojas-Líbano et al.). Dessa forma, a escolha deste tema e desenvolvimento sob a licença GPL-3.0 reflete tanto a relevância acadêmica do Projeto Integrador IV quanto a entrega de uma solução de baixo custo, escalável e de alto valor prático para o enfrentamento dos desafios da alfabetização e letramento.

3 DESCRIÇÃO DA SOCIEDADE IMPACTADA

A sociedade impactada por este projeto é composta principalmente por estudantes em fase de alfabetização e nos anos iniciais do ensino fundamental, professores da educação básica, instituições de ensino (com ênfase naquelas com recursos limitados) e as famílias dos alunos. Esses grupos foram selecionados por vivenciarem diretamente os desafios do desenvolvimento da leitura e por serem os agentes centrais na promoção de um ambiente educacional mais inclusivo e adaptativo.

Os estudantes representam o principal grupo beneficiado, especialmente aqueles que apresentam dificuldades de aprendizagem ou condições de neurodesenvolvimento atípicas, como dislexia e TDAH. Frequentemente, essas crianças lidam com frustrações no percurso escolar devido à identificação tardia de suas dificuldades. Ao viabilizar o mapeamento de seus padrões de leitura no próprio ambiente escolar e com total respeito à sua privacidade (conforme a LGPD), o projeto possibilita que esses alunos recebam intervenções pedagógicas mais ágeis, tornando o processo de aprendizagem mais acolhedor e menos excludente.

Os professores e educadores constituem o grupo de usuários diretos da solução e são fortemente impactados. Atualmente, esses profissionais carecem de ferramentas tecnológicas acessíveis que forneçam dados objetivos sobre o processo cognitivo de leitura de seus alunos. O EyeLearn impacta esse grupo ao traduzir dados complexos de rastreamento ocular em um painel visual de indicadores claros. Isso empodera o docente, fornecendo evidências concretas para embasar adaptações metodológicas e estratégias de ensino personalizadas, sem atribuir a ele a responsabilidade de um diagnóstico clínico.

As instituições de ensino e as famílias também compõem uma parcela essencial da sociedade impactada. Para as escolas, sobretudo as da rede pública, o projeto promove a democratização do acesso a tecnologias de ponta, substituindo hardwares de altíssimo custo por webcams comuns e software de código aberto. Para as famílias, a identificação precoce de divergências nos padrões de leitura pela escola atua como um sinalizador importante, facilitando e acelerando o

encaminhamento da criança para a avaliação de profissionais de saúde capacitados, quando necessário.

O impacto do projeto será medido por meio de sua viabilidade técnica em democratizar o rastreamento ocular em hardwares de baixo custo e pela eficácia de sua interface em auxiliar o corpo docente na tomada de decisão pedagógica. Dessa forma, o projeto não se limita ao desenvolvimento de uma prova de conceito em visão computacional, mas consolida-se como uma ferramenta de tecnologia assistiva focada na equidade educacional, na ética no tratamento de dados infantis e no suporte prático à alfabetização.

4 METODOLOGIA

A metodologia deste projeto é quantitativa e experimental, e se divide em duas frentes. A primeira consiste em treinar um modelo de classificação a partir de dados de rastreamento ocular. A segunda consiste em testar o software produzido, verificando sua corretude e o quanto ele resiste à perda de qualidade do sinal de entrada. As etapas estão descritas a seguir.

4.1 Fontes de Dados e Coleta

Utilizaremos bases de dados públicas já disponíveis para pesquisa. Essa escolha evita a coleta de dados junto a crianças e permite comparar nossos resultados com os de trabalhos anteriores que usaram as mesmas bases.

- **ETDD70 (Eye-Tracking Dyslexia Dataset):** base principal do trabalho. Reúne registros de rastreamento ocular de 70 estudantes tchecos de 9 e 10 anos, sendo 35 com diagnóstico de dislexia e 35 sem dificuldades de leitura. Os dados foram coletados em três tarefas: leitura de sílabas, leitura de texto com sentido e leitura de pseudotexto. A base está disponível no repositório Zenodo e foi aprovada pelo comitê de ética da Universidade Masaryk (Dostálová et al., 2024);
- **Saliency4ASD:** base secundária. Contém movimentos oculares de 28 crianças de 5 a 12 anos, sendo 14 com transtorno do espectro autista e 14 com desenvolvimento típico, observando livremente imagens de cenas naturais. Serve para testar se as características que extraímos funcionam também em outra condição e em outro tipo de tarefa (Saliency4ASD, 2024);
- **Coleta própria para validação do módulo de captura:** faremos gravações por webcam com os próprios integrantes do grupo, apenas para verificar se o módulo de aquisição do olhar funciona. Esses dados não entram no treinamento nem na avaliação dos modelos.

4.2 Ferramentas e Infraestrutura Tecnológica

A infraestrutura tecnológica para o desenvolvimento do projeto compreende:

- **Linguagem de Programação:** Python, com NumPy e Pandas para tratar as séries de coordenadas do olhar, Scikit-learn (Pedregosa et al., 2011) e

XGBoost (Chen e Guestrin, 2016) para a modelagem e Matplotlib para os gráficos;

- **Visão Computacional:** OpenCV e MediaPipe Face Landmarker (Lugaresi et al., 2019), usados para detectar o rosto e a íris nas imagens da webcam e estimar a direção do olhar;
- **Interface Gráfica:** PyQt6, usado tanto na tela de atividades do aluno quanto no painel do professor, que são dois modos da mesma aplicação. Os gráficos do painel são gerados com Matplotlib embutido na interface, sem necessidade de servidor ou de tráfego de dados pela rede;
- **Testes:** Pytest para os testes automatizados e o relatório de cobertura, Hypothesis (MacIver et al., 2019) para os testes baseados em propriedades e Mutmut para o teste de mutação;
- **Gestão de Versão:** GitHub para o código-fonte e a documentação, com o GitHub Actions rodando a suíte de testes a cada alteração enviada ao repositório.

4.3 Técnicas de Inteligência Artificial e Processamento

O projeto aplicará o seguinte fluxo técnico:

- **Pré-processamento do sinal:** descartaremos as amostras perdidas por piscadas e falhas de rastreamento, suavizamos as séries de coordenadas e separamos o percurso do olhar em fixações e sacadas. Para essa separação usaremos os algoritmos I-VT, baseado em limiar de velocidade, e I-DT, baseado em dispersão, ambos descritos e comparados por Salvucci e Goldberg (2000);
- **Engenharia de características:** extraímos as medidas usadas na literatura de leitura, como a quantidade e a duração média das fixações, a amplitude das sacadas, a proporção de sacadas regressivas e o tempo total de leitura. Vajs et al. (2023) mostram que medidas desse tipo, quando bem escolhidas, permanecem interpretáveis e ainda assim discriminam bem entre leitores disléxicos e não disléxicos;
- **Modelagem preditiva:** treinaremos e compararemos quatro algoritmos: SVM, Random Forest, XGBoost e uma rede neural convolucional unidimensional

aplicada diretamente à série temporal. Os hiperparâmetros serão ajustados por busca em grade;

- **Estratégia de validação:** usaremos validação cruzada estratificada com separação por sujeito, de modo que nenhum participante apareça ao mesmo tempo no treino e no teste. Sem esse cuidado o modelo tende a decorar características do indivíduo, e o desempenho medido aparece inflado;
- **Análise de degradação do sinal:** é o experimento principal do trabalho. Os dados do ETDD70 vêm de um equipamento de bancada, bem mais preciso do que uma webcam comum. Vamos degradá-los aos poucos, reduzindo a taxa de amostragem e somando ruído gaussiano, para simular a qualidade de uma câmera de uso geral. A pergunta tem precedente na literatura: Vajs et al. (2023) reduziram a taxa de aquisição de 60 Hz para 30 Hz e a acurácia caiu de 88,9% para 87,8%, o que sugere que a taxa de amostragem sozinha não inviabiliza a classificação. Resta saber o que acontece quando também há perda de precisão espacial, já que sistemas baseados em câmera de celular operam na faixa de 0,6 a 1 grau de erro mesmo após calibração individual (Valliappan et al., 2020). Mediremos, portanto, a curva de acurácia em função do nível de degradação, e com ela o ponto até onde uma solução de baixo custo ainda se sustenta.

4.4 Estratégia de Verificação e Validação de Software

Modelos de aprendizado de máquina não têm um oráculo que diga se uma saída específica está certa. Por isso a estratégia de teste combina técnicas tradicionais com técnicas próprias de sistemas com inteligência artificial:

- **Teste unitário e de integração:** cobrem as funções puras do pipeline. O extrator de características será testado com percursos sintéticos, em que já sabemos de antemão quantas fixações e sacadas existem. Acompanharemos o percentual de cobertura de código;
- **Teste baseado em propriedades:** o Hypothesis gera entradas aleatórias e verifica se o sistema mantém suas invariantes, como não lançar exceções, não devolver valores indefinidos e não produzir características fora do domínio esperado (MacIver et al., 2019);

- **Teste metamórfico:** técnica proposta por Chen, Cheung e Yiu (1998) justamente para casos em que não existe oráculo. Em vez de conferir a saída isolada, verificam-se relações entre entradas e saídas: espelhar o percurso na horizontal não deve mudar a classe prevista, e um ruído pequeno não deve inverter a predição. Xie et al. (2011) demonstram a aplicação dessas relações especificamente a classificadores de aprendizado de máquina;
- **Teste de mutação:** o Mutmut insere defeitos artificiais no código para medir se a suíte de testes é capaz de detectá-los, produzindo o escore de mutação. Jia e Harman (2011) apresentam o histórico e a fundamentação da técnica;
- **Teste de vazamento de dados:** um teste automatizado confere se algum identificador de sujeito aparece simultaneamente no treino e no teste. É o erro metodológico mais comum nesse tipo de experimento, e um teste barato o impede;
- **Automação:** a suíte inteira roda no GitHub Actions a cada envio de código, o que permite detectar regressões cedo.

4.5 Métricas de Avaliação

A avaliação do projeto será feita em três dimensões:

- **Indicadores de desempenho do modelo:** acurácia, sensibilidade, especificidade, F1-score e área sob a curva ROC, com matriz de confusão e intervalos de confiança obtidos a partir das repetições da validação cruzada. Calcularemos também o valor preditivo positivo ajustado à prevalência real da dislexia na população escolar, que indica quantos falsos positivos esperar em uso real. Esse número costuma ser bem menos otimista que a acurácia: Perochon et al. (2023), avaliando um aplicativo de rastreio com área sob a curva de 0,90, relatam valor preditivo positivo de 63,4% mesmo quando o resultado é combinado a um questionário validado;
- **Indicadores de qualidade de software:** cobertura de código, escore de mutação, número de propriedades e de relações metamórficas verificadas e taxa de sucesso das execuções na integração contínua;
- **Indicadores qualitativos:** quais características o modelo considera mais importantes e se elas fazem sentido diante do que a literatura de leitura

descreve, além da clareza das informações apresentadas ao professor no painel.

4.6 Aspectos Éticos e de Privacidade

Os dados envolvidos são sensíveis, o que exige alguns cuidados:

- **Uso de bases públicas anonimizadas:** o treino e a avaliação usam apenas conjuntos já anonimizados e liberados para pesquisa. Não haverá coleta de dados com crianças;
- **Processamento local e não retenção de imagens:** no módulo de captura, os quadros da webcam são processados na memória do próprio computador e descartados logo após a extração das coordenadas do olhar. Nenhuma imagem de rosto é gravada ou enviada para fora do dispositivo. Imagem facial é dado biométrico, e portanto dado pessoal sensível segundo o artigo 5º da Lei Geral de Proteção de Dados (Brasil, 2018);
- **Delimitação do uso pretendido:** o sistema é uma ferramenta de apoio à observação do professor, não um instrumento de diagnóstico clínico. O painel descreve o padrão de leitura observado e sugere adaptações pedagógicas. Em nenhum momento atribui um rótulo diagnóstico ao aluno.

5 PLANO DE TRABALHO

O projeto será executado em cinco etapas, garantindo que a coleta, o processamento e a visualização dos dados sigam um processo técnico e estatístico.

ETAPA	DESCRIÇÃO DA ATIVIDADE	ENTREGA
Levantamento e Preparação dos Dados	Organização das bases públicas (ETDD70 e Saliency4ASD) e validação inicial da captura via webcam.	Ambiente configurado e dados prontos para uso.
Pré-processamento e Extração de Características	Limpeza do sinal do olhar e extração das métricas de leitura (fixações, sacadas e regressões).	Código de extração de métricas testado e funcional.
Experimento de Degradação de Sinal	Simulação de perda de qualidade de webcam (redução de frequência e adição de ruído).	Análise do impacto da perda de qualidade no sinal.
Modelagem Preditiva	Treinamento dos algoritmos de classificação (SVM, Random Forest, XGBoost) e aplicação dos testes automatizados de software.	Modelos treinados, avaliados e validados.
Desenvolvimento do Painel e Finalização	Criação da interface em PyQt6/Matplotlib para o professor, escrita do relatório e preparação da apresentação.	Painel funcional, Relatório Final e repositório GitHub.

REFERÊNCIAS

- Brasil (2018). Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/113709.htm
- Chen, T.; Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Disponível em: <https://doi.org/10.1145/2939672.2939785>
- Chen, T. Y.; Cheung, S. C.; Yiu, S. M. (1998). Metamorphic testing: a new approach for generating next test cases. Relatório Técnico HKUST-CS98-01, Hong Kong University of Science and Technology.
- Dostálová, N.; Švaříček, R.; Sedmidubský, J.; Culemann, W.; Šašinka, Č.; Zezula, P.; Čeněk, J. (2024). ETDD70: Eye-Tracking Dyslexia Dataset. Zenodo. Disponível em: <https://doi.org/10.5281/zenodo.13332134>
- Jia, Y.; Harman, M. (2011). An Analysis and Survey of the Development of Mutation Testing. IEEE Transactions on Software Engineering. Disponível em: <https://doi.org/10.1109/TSE.2010.62>
- Lugaresi, C. et al. (2019). MediaPipe: A Framework for Building Perception Pipelines. arXiv. Disponível em: <https://arxiv.org/abs/1906.08172>
- MacIver, D. R.; Hatfield-Dodds, Z. et al. (2019). Hypothesis: A new approach to property-based testing. Journal of Open Source Software. Disponível em: <https://doi.org/10.21105/joss.01891>
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>
- Perochon, S. et al. (2023). Early detection of autism using digital behavioral phenotyping. Nature Medicine. Disponível em: <https://doi.org/10.1038/s41591-023-02574-3>
- Saliency4ASD (2024). A dataset of eye movements for the children with autism spectrum disorder. Zenodo. Disponível em: <https://zenodo.org/records/13960426>
- Salvucci, D. D.; Goldberg, J. H. (2000). Identifying fixations and saccades in eye-tracking protocols. Proceedings of the 2000 Symposium on Eye Tracking Research & Applications. Disponível em: <https://doi.org/10.1145/355017.355028>
- Vajs, I.; Papić, T.; Ković, V.; Savić, A. M.; Janković, M. M. (2023). Accessible Dyslexia Detection with Real-Time Reading Feedback through Robust Interpretable Eye-Tracking Features. Brain Sciences. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10046816/>
- Valliappan, N. et al. (2020). Accelerating eye movement research via accurate and affordable smartphone eye tracking. Nature Communications. Disponível em: <https://doi.org/10.1038/s41467-020-18360-5>

Xie, X. et al. (2011). Testing and validating machine learning classifiers by metamorphic testing. Journal of Systems and Software. Disponível em:
<https://www.sciencedirect.com/science/article/abs/pii/S0164121210003213>

